

курс «Прикладные задачи анализа данных»

Функции ошибки / функционалы качества

Часть 1: Задачи регрессии

Александр Дьяконов

02 октября 2020 года



План на несколько лекций

задача регрессии

задача бинарной классификации

- **чёткая классификация**
- **скоринговые функции**

задача классификации с несколькими классами

задачи ранжирования

задачи кластеризации

Задача – ДНК

Дано

Найти

Критерий

Построить алгоритм легко!

Чтобы улучшить... надо уметь оценивать.

Метрики

- **функции ошибки**
- **функционалы качества**

Функции ошибки / функционалы качества

Пожалуй, **самое главное** при решении задачи...
иногда важнее данных!


а что такое решение!

В анализе данных:

- формализация ответа (формат)
- как ответ оценивается (критерий качества)



Случай из практики: задача про траектории зрачка
(задача с 3 классами, а не с двумя)

Задача регрессии




Задача регрессии

Будем дальше пытаться всё решать в классе констант



1. Простейшее решение
2. Примерно это и происходит в листьях решающих деревьев
3. Раскрывает природу функционалов

Средний модуль отклонения – Mean Absolute Error (MAE), Mean Absolute Deviation (MAD)

$$\text{MAE} = \frac{1}{m} \sum_{i=1}^m |a_i - y_i|$$


Напоминание:

$$\frac{1}{m} \sum_{i=1}^m |a - y_i| \rightarrow \min$$

$$a = \text{median}(\{y_i\}_{i=1}^m)$$

Это открывает смысл решений!

Средний модуль отклонения



Средний модуль отклонения

Способы использования тайных знаний:


- **медиана, вместо усреднения, в ансамбле**
- **округление ответа (если целевой вектор целочисленный)**

Откуда берётся MAE

$$y = a_w(x) + \varepsilon$$

w – параметры алгоритма $a_w(x)$

$$\varepsilon \sim \text{laplace}(0, \alpha)$$



Для оценки параметров выписываем правдоподобие модели

$$p(y | x, w) = \frac{\alpha}{2} \exp[-\alpha |y - a_w(x)|]$$

Метод максимального правдоподобия:

$$\begin{aligned} \log L(w) &= \log \prod_{i=1}^m p(y_i | x_i, w) = \\ &= \sum_{i=1}^m \left[\log \frac{\alpha}{2} - \alpha |y_i - a_w(x_i)| \right] \rightarrow \max \end{aligned}$$

Откуда берётся MAE

Получаем

$$\alpha \sum_{i=1}^m |y_i - a_w(x_i)| \rightarrow \min$$

т.е. задачу минимизации MAE!


- не зависит от природы модели
- зависит от распределения ошибок
(почему Residual Plots)

Максимизация правдоподобия эквивалентна минимизации MAE!

Чему соответствует минимизация весового MAE?

Средний квадрат отклонения ~ Mean Squared Error (MSE)

$$\text{MSE} = \frac{1}{m} \sum_{i=1}^m |a_i - y_i|^2$$




$$\frac{1}{m} \sum_{i=1}^m |a - y_i|^2 \rightarrow \min$$

$$a = \frac{1}{m} \sum_{i=1}^m y_i$$

Root Mean Squared Error (RMSE) / Root Mean Square Deviation (RMSD)

$$\text{RMSE} = \sqrt{\frac{1}{m} \sum_{i=1}^m |a_i - y_i|^2}$$

Средний квадрат отклонения ~ Mean Squared Error (MSE)



Способы использования тайных знаний

- ничего не делать (в RF, GBM и т.д. всё равно усредняют)
- метод НСКО – классическая регрессия!

Нормированная версия: коэффициент детерминации R^2 (Coefficient of Determination)

$$R^2 = 1 - \frac{\sum_{i=1}^m |a_i - y_i|^2}{\sum_{i=1}^m |\bar{y} - y_i|^2}$$

$$\bar{y} = \frac{1}{q} \sum_{i=1}^m y_i$$

В общем случае (в статистике) коэффициент детерминации:


$$R^2 = 1 - \frac{\mathbf{D}(y | x)}{\mathbf{D}(y)}$$

Откуда берётся (R)MSE

$$y = a_w(x) + \varepsilon$$

w – параметры алгоритма $a_w(x)$

$$\varepsilon \sim \text{norm}(0, \sigma^2)$$



Для оценки параметров выписываем правдоподобие модели

$$p(y | x, w) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left[-\frac{(y - a_w(x))^2}{2\sigma^2}\right]$$

Метод максимального правдоподобия:

$$\begin{aligned} \log L(w) &= \log \prod_{i=1}^m p(y_i | x_i, w) = \\ &= \sum_{i=1}^m \left[-\frac{1}{2} \log(2\pi\sigma^2) - \frac{(y_i - a_w(x_i))^2}{2\sigma^2} \right] \rightarrow \max \end{aligned}$$

Откуда берётся (R)MSE

Получаем

$$\frac{1}{2\sigma^2} \sum_{i=1}^m (y_i - a_w(x_i))^2 \rightarrow \min$$

т.е. задачу минимизации MSE!

- не зависит от природы модели
- зависит от распределения ошибок
(почему Residual Plots)

Максимизация правдоподобия эквивалентна минимизации среднеквадратичной ошибки!

Д3 Каким ещё распределениям какие ошибки соответствуют?

Откуда берётся (R)MSE: ещё одно «оправдание»

Пусть функция ошибки $l(y, a) = g(y - a)$

Что логично?

1. $g(0) = 0$

2. $|z_1| \leq |z_2| \Rightarrow g(z_1) \leq g(z_2)$


3. достаточно гладкая...

$$g(z) = g(0) + g'(0)z + \frac{g''(0)}{2}z^2 + o(z^2)$$

но тогда

$$l(y, a) = g(y - a) \approx \underbrace{g(0)}_{=0(1)} + \underbrace{g'(0)(y - a)}_{=0(2)} + \frac{g''(0)}{2}(y - a)^2 = \underbrace{C}_{>0}(y - a)^2$$

Функция Хьюбера и logcosh




$$\text{huber}_\delta(z) = \begin{cases} \frac{1}{2}z^2, & |z| \leq \delta, \\ \delta \left(|z| - \frac{1}{2}\delta \right), & |z| > \delta. \end{cases}$$

Как только что вывели:

когда отклонение мало – ошибка квадратичная
когда велико (в т.ч. выбросы) – линейная

Функция Хьюбера и logcosh

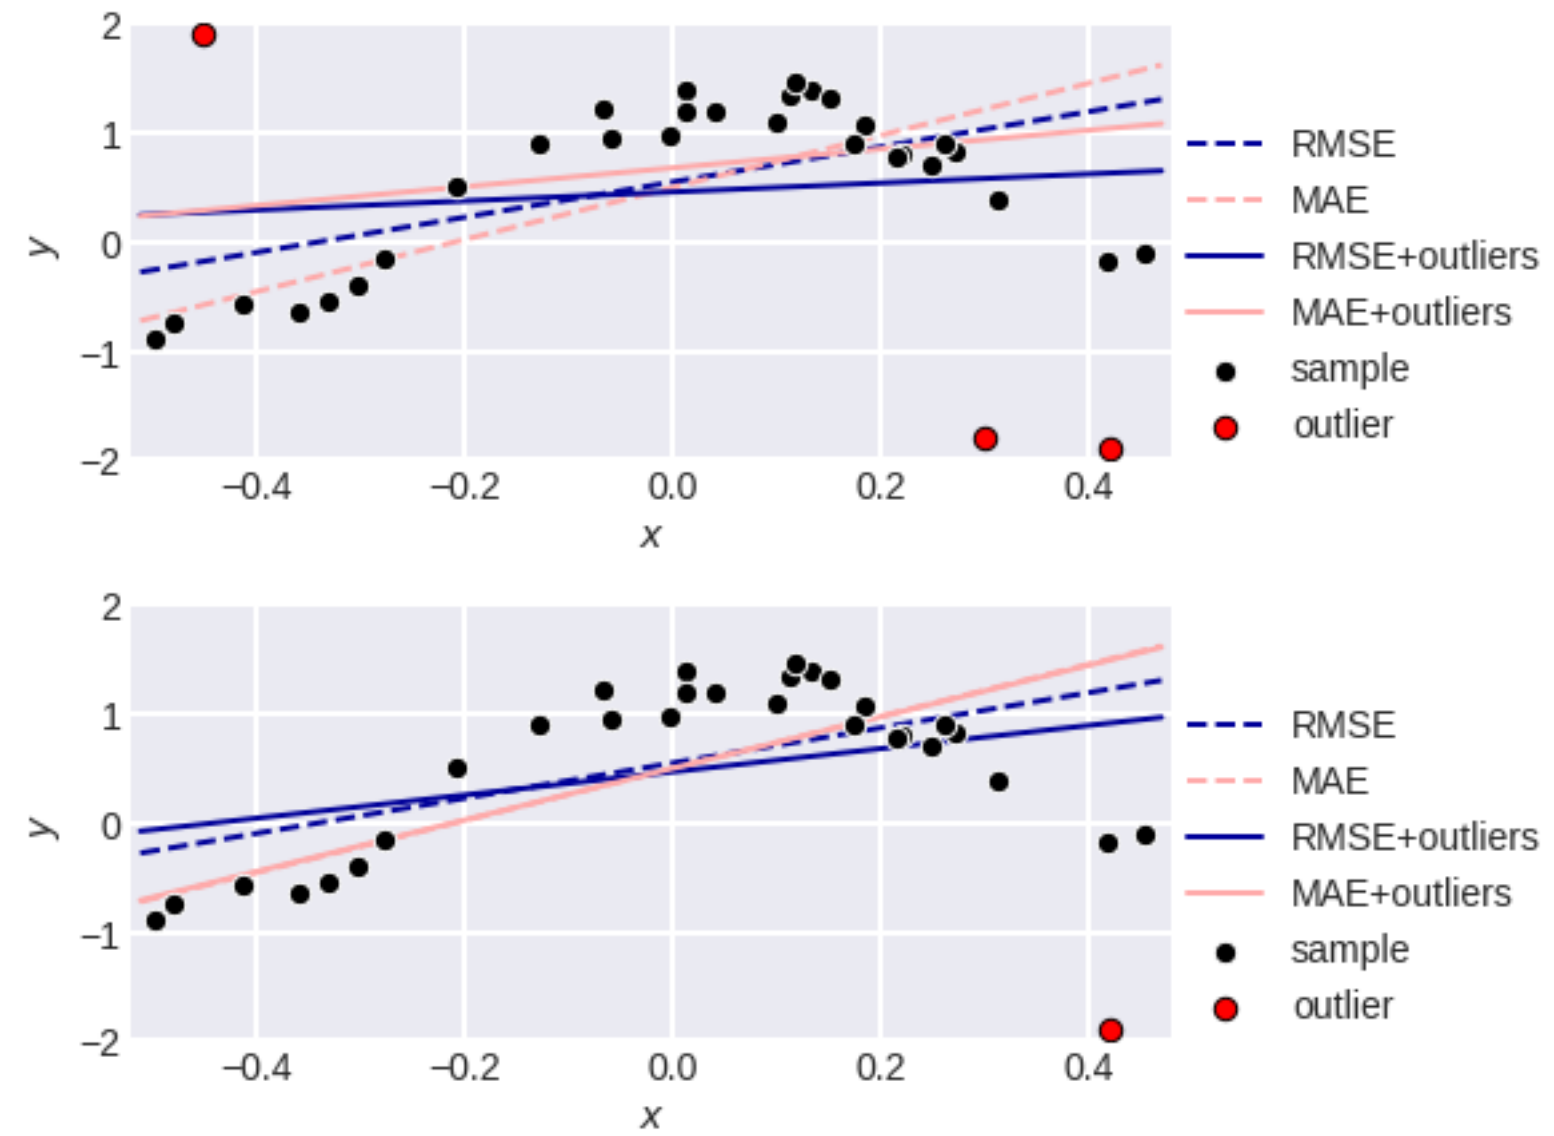


$$\text{logcosh} = \log\left(\frac{\exp(z) + \exp(-z)}{2}\right)$$

**непараметрическая,
но используется редко.**


Различия MSE и MAE

Устойчивость к выбросам...



Различия MSE и MAE


Устойчивость к выбросам...



Считается, что MAE устойчивее к выбросам...

Д3 Честный эксперимент: зависимость результата от функций ошибок / выбросов


Различия MSE и MAE



посмотрим на неконстантное решение:


$$\sum_{i=1}^m |y_i - a(x_i)|^p \rightarrow \min,$$
$$a(x) = \alpha x + \beta$$

MAE




внутри «треугольника»
одинаковый MAE=1.5

RMSE



Huber ($\delta = 1$)



Различия MSE и MAE

внутри «треугольника» одинаковый $MAE=1.5$

**можно привести примеры, когда MAE меняется слабо,
а RMSE значительно**

Д3 Хороший нетривиальный пример / может ли быть наоборот?

Обобщения


$$\sqrt[p]{\frac{1}{m} \sum_{i=1}^m w_i |\varphi(a_i) - \varphi(y_i)|^p} \qquad \sum_{i=1}^m w_i = 1, \quad w_1, \dots, w_m \geq 0$$

Рецепты


1. Преобразование целевого вектора $\varphi(y)$
2. Веса ~ вероятности появления объектов в сэмплировании
Некоторые модели поддерживают веса объектов
3. В случае нетривиальных p – прямая настройка

Дальше к этому вернёмся...

Про нетривиальные p



Как точка минимума зависит от степени



Разные постановки задачи регрессии

$$\|Xw - y\|_p \rightarrow \min$$

$p < 1$	Это не норма, NP-сложная задача
$p = 1$	Линейное программирование
$1 < p < 2$	Нет стандартных методов
$p = 2$	Аналитическое решение (линейная алгебра)
$p > 2$	Градиентные методы
$p = \infty$	Линейное программирование

Symmetric mean absolute percentage error (SMAPE or sMAPE)

$$\text{SMAPE} = \frac{2}{m} \sum_{i=1}^m \frac{|y_i - a_i|}{y_i + a_i} = 100\% \cdot \frac{1}{m} \sum_{i=1}^m \frac{|y_i - a_i|}{(y_i + a_i) / 2}$$

**Когда надо интерпретировать погрешность как проценты
– плохо, если есть нули (и отрицательные значения)**

1 – 2
SMAPE = 67%

100 – 101
SMAPE = 1%

0 – 1
SMAPE = 200%

Начальники не знают, что такое проценты...

Применение SMAPE – прогноз временных рядов

Mean Absolute Percent Error (MAPE)

$$\text{MAPE} = \frac{1}{m} \sum_{i=1}^m \frac{|y_i - a_i|}{|y_i|}$$

Чем MAPE явно лучше SMAPE на практике?


Mean Absolute Percent Error (MAPE)

$$\text{MAPE} = \frac{1}{m} \sum_{i=1}^m w_i |y_i - a_i|$$

$$w_i = \frac{1}{|y_i|}$$


Просто весовой MAE!
как оптимизировать? дальше...

MAPE и SMAPE




Что настораживает в этом графике?


MAPE и SMAPE



Масштаб! Типичная ошибка (и во многих курсах)



MAPE и SMAPE



**Например, MAPE – весовой MAE,
но на практике веса не сильно отличаются!**

Поэтому решение около медианы

Д3 Предложить минимизацию для MAPE и SMAPE (обосновать в экспериментах)

PMAD

Другой способ нормировки ошибки...

$$\text{PMAD} = \frac{\sum_{i=1}^m |y_i - a_i|}{\sum_{i=1}^m |y_i|}$$

эквивалентен MAE

Д3 Как на типичных и специальных выборках соотносятся решения задач минимизации перечисленных функций ошибки?

Меры на сравнении с бенчмарком

Классная идея:

сделать простой алгоритм и смотреть ошибку относительно него

**Mean Relative Absolute Error
(MRAE)**

$$\text{MRAE} = \frac{1}{m} \sum_{i=1}^m \frac{|y_i - a_i|}{|y_i - a'_i|}$$

REL_MAE

$$\text{REL_MAE} = \frac{\sum_{i=1}^m |y_i - a_i|}{\sum_{i=1}^m |y_i - a'_i|}$$

Percent Better

$$\text{PB(MAE)} = \frac{1}{m} \sum_{i=1}^m I[|y_i - a_i| < |y_i - a'_i|]$$

Меры на сравнении с бенчмарком

Как выбрать бенчмарк в задачах прогнозирования?

Нормированные ошибки

Не зависят от шкалы...

Mean Absolute Scaled Error

$$\text{MASE} = \frac{1}{\frac{m}{m-1} \sum_{i=2}^m |y_i - y_{i-1}|} \sum_{t=1}^m |y_t - a_t|$$


Какие ещё бывают функционалы в регрессии?

С точностью до порога**функция ошибки**




$$eB = \frac{1}{m} \sum_{i=1}^m I[|y_i - a_i| > \varepsilon]$$

функционал качества

$$eB = \frac{1}{m} \sum_{i=1}^m I[|y_i - a_i| < \varepsilon]$$

был в задаче Dunnhumby**Оптимальное решение – мода парzenовской плотности**


С точностью до порога



Д3 Реализуйте многомерную линейную регрессию, оптимизирующую ϵ .


Несимметричные функции потерь

$$\frac{1}{m} \sum_{i=1}^m \begin{cases} g(|y_i - a_i|), & y_i < a_i, \\ h(|y_i - a_i|), & y_i \geq a_i, \end{cases}$$



Зачем нужны такие функции?

Несимметричные функции потерь



$$\frac{1}{m} \sum_{i=1}^m \begin{cases} k_1 |y_i - a_i|, & y_i < a_i, \\ k_2 |y_i - a_i|, & y_i \geq a_i, \end{cases}$$

Д3 Реализуйте многомерную линейную регрессию, оптимизирующую такую функцию.

Совет


Функции ошибок иногда и классные признаки...

Пример: в Casualty придумываем бенчмарки
(восстановление одной переменной по другой),
признаки – их относительные ошибки,
т.к. абсолютные брать нельзя

Почему?

Совет

Аналогично во многих задачах с сигналами...



**Признак – не только коэффициенты в приближении,
но и ошибка приближения!**

~ отклонение от типичного поведения

Монотонное изменение функции ошибки

Формально задачи эквивалентные:

$$\text{MSE} \rightarrow \min$$

$$\frac{1}{m} \sum_{i=1}^m |a - y_i|^2 \rightarrow \min$$

$$\text{RMSE} \rightarrow \min$$

$$\sqrt{\frac{1}{m} \sum_{i=1}^m |a_i - y_i|^2} \rightarrow \min$$

Решения на практике могут отличаться...

В методе градиентного спуска разные производные

$$\frac{\partial \text{MSE}}{\partial a} = \frac{2}{m} \sum_{i=1}^m (a - y_i)$$

$$\frac{\partial \text{RMSE}}{\partial a} = \frac{1}{m \text{RMSE}} \sum_{i=1}^m (a_i - y_i)$$

ДЗ На что это влияет на практике? что лучше минимизировать?

Рассмотреть ещё подобные случаи в ML!

Метрики в регрессии: минутка кода

```
from sklearn.metrics import r2_score
from sklearn.metrics import mean_absolute_error
from sklearn.metrics import mean_squared_error
from sklearn.metrics import mean_squared_log_error
from sklearn.metrics import median_absolute_error
from sklearn.metrics import explained_variance_score

# R^2
print (r2_score(y, a),
       1 - np.mean((y - a) ** 2) / np.mean((y - np.mean(y)) ** 2))


# MAE
print (mean_absolute_error(y, a),
       np.mean(np.abs(y - a)))

# MSE
print (mean_squared_error(y, a),
       np.mean((y - a) ** 2))

# MSLp1E
print (mean_squared_log_error(y, a),
       np.mean((np.log1p(y) - np.log1p(a)) ** 2))

# MedAE
print (median_absolute_error(y, a),
       np.median(np.abs(y - a)))
```

Сравнение метрик в одном эксперименте



**Д3 Что за эксперимент? Почему ошибки ведут себя так?
(попробовать восстановить)**

Д3 Как число фолдов влияет на CV-оценку ошибки?

Д3 Как шум влияет на выбор оптимального решения?

Итоги

Функции ошибки имеют вероятностное обоснование
(через правдоподобие)

средний модуль отклонения MAE (MAD)

средний квадрат отклонения MSE

+ RMSE, коэффициент детерминации R^2 , функция Хьюбера, Logcosh
Можно невероятно обосновать для малых отклонений

Иногда попадаются обобщения MAE и RMSE

Итоги

Процентные функции ошибок
(SMAPE, MAPE, PMAD)

Основанные на сравнении с бенчмарком
(MRAE, REL_MAE, PB)

Нормированные ошибки
(MASE)

Несимметричные ошибки

Ошибки с точностью до порога

Есть нетрадиционные применения функций ошибок
для генерации признаков

Литература

Стрижов В.В. Функция ошибки в задачах восстановления регрессии //
Заводская лаборатория, 2013, 79(5): 65-73.

<http://strijov.com/papers/Strijov2012ErrorFn.pdf>

«How to Win a Data Science Competition: Learn from Top Kagglers»

<https://ru.coursera.org/learn/competitive-data-science>

конспект этих лекций

<https://dyakonov.org/2018/10/23/функции-ошибок-в-задачах-регрессии/>